Paris Attacks

A pretext to sentiment analysis on social media

M. GABORIT – F. BLAIN

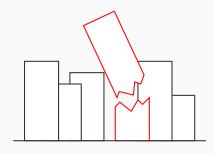
HAUM Talks - Janvier 2016

Au Menu

- 1. L'idée
- 2. Mise en oeuvre
- 3. Hypothèses et Pistes
- 4. Ce que font les autres

L'idée

Nouvelle vision des évènements



Nouvelle vision des évènements



Un évènement entraîne une réaction publique et spontannée.

Attaques terroristes du 13 novembre

Très particulières pour plusieurs raisons :

- inattendues
- énormément de victimes et de témoins
- touchant une population assez jeune [●]
- · revendiquées a posteriori



Attaques terroristes du 13 novembre

Réactions à la hauteur des attaques :

- énormément de messages postés (population connectée)
- · réactions suivies sur plusieurs heures/jours ?
- utilisation de téléphones portables ⇒ données géolocalisées
- · grande variabilité des réactions dans le temps

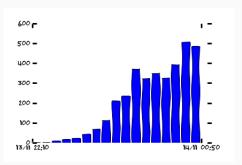


Figure 1: Évolution du nombre de tweets postés dans les premières heures

Proposition

Est-il possible d'extraire des temps caractéristiques sociaux des tweets postés en rapport avec les attaques ?

Proposition

Est-il possible d'extraire des temps caractéristiques sociaux des tweets postés en rapport avec les attaques ?

Temps caractéristique : temps permettant de distinguer différents évènements et/ou d'évaluer la vélocité de leur réponse.

Pourquoi les tweets?

- · Format court
 - · Facile à analyser
 - · Propice à des réactions claires et distingables ¹⁰
 - Rédaction faiblement réfléchie («à chaud»)
- · Facilité de récupération
 - · Utilisation du format natif de MongoDB
 - · Traitement off-line efficace
 - · Plusieurs passes possibles
- · Grande taille du jeu de données (plusieurs milliers de tweets)

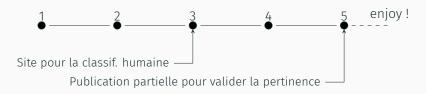




Mise en oeuvre

Plan de bataille

- 1. Récupérer les tweets pour une analyse hors ligne (#ParisAttacks)
- 2. Classer les tweets suivant le langage
- 3. Classer manuellement un sous-ensemble de tweets
- 4. Utiliser le sous-ensemble classé pour classer automatiquement le reste
- 5. Proposer des observables afin de déduire les temps caractéristiques sociaux



Hypothèses et Pistes

Hypothèses

Réactions suivies

Peu d'ambiguité

Changement post-revendication

Hypothèses

Réactions suivies

A vérifier en suivant l'activité des comptes parmis les tweets récupérés

Peu d'ambiguité

Hypothèse raisonnable dans un cadre post-traumatique, soutenue par le format court.

Changement post-revendication

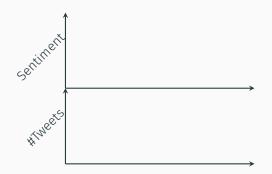
A analyser à vérifier *a posteriori...* peut être faudra-t-il exclure les tweets évoquant Daech directement

Pistes

- Utiliser la géolocalisation pour analyser les données avec une composante géographique
- Corréler les résultats avec la parution de reportages/d'images/d'informations
- Comparer avec d'autres évènements marquants (sportifs, politiques, etc...)
- Analyse par canaux :
 - · sources médiatiques
 - politique
 - · autres...

Pistes

- Mettre en regard avec les évènements de Charlie Hebdo (hypothèse de réaction couplée)
- Auto-émulation ou réponse à un stimulus (tweet d'un politique, d'un média)
- Analyse bi-variante

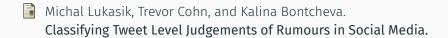


A propos des statistiques

- · Panel non-représentatif de la population
- Premières réactions biaisées par les annonces des journaux télévisés (le media n'est jamais impartial)
- · Biais induit par la classification manuelle
- · etc...

Ce que font les autres

Ce que font les autres



In Proceedings of EMNLP, volume 796, pages 2590–2595, 2015.

Michal Lukasik, Trevor Cohn, and Kalina Bontcheva.

Modeling Tweet Arrival Times using Log-Gaussian Cox

Processes.

In Proceedings of EMNLP, volume 796, pages 250–255, 2015.

Laurent Luce.
Twitter sentiment analysis using Python and NLTK.

Oriane Piquer-Louis.

Documenter l'expérience habitante de la ville sur les réseaux sociaux : corpus photographiques et données numériques, le sens des collections.

Merci!

Des questions?

 ${\tt fred@haum.org-mathieu@haum.org}$

On accepte aussi les coups de main!